

## 6.4 Symmetric Matrices

- 대칭 행렬의 경우 Eigenvalue와 pivot값의 관계
  - ▣ Eigenvalue는  $\det(A - \lambda I) = 0$ 에서 얻음
  - ▣ Pivot값들은 가우스 소거 과정에서 얻음
  - ▣ 지금까지 배운 유일한 관련성
    - (pivot값들의 곱)=행렬식=(eigenvalue값들의 곱)
  - ▣ **대칭행렬**의 경우 다음이 성립
    - (양수인 pivot값들의 개수)=(양수인 eigenvalue들의 개수)

## 6.4 Symmetric Matrices

- (계속) 대칭 행렬의 경우 Eigenvalue와 pivot값의 관계

- Example

- $A = \begin{bmatrix} 1 & 3 \\ 3 & 1 \end{bmatrix} \rightarrow$  소거법  $\begin{bmatrix} 1 & 3 \\ 0 & -8 \end{bmatrix}$

- ➔ eigenvalue의 합이 2, 곱이 -8이므로 eigenvalue는 4, -2

- ➔ pivot값은 1, -8 이므로 양수의 eigenvalue와 pivot은 1개임

- $B = \begin{bmatrix} 1 & 6 \\ -1 & -4 \end{bmatrix} \rightarrow$  소거법  $\begin{bmatrix} 1 & 6 \\ 0 & 2 \end{bmatrix}$

- ➔ eigenvalue의 합이 -3, 곱이 2이므로 eigenvalue는 -2, -1

- ➔ pivot값은 1, 2 이므로 eigenvalue와 pivot의 양수의 개수가 다름

- ➔ 대칭이 아님

## 6.4 Symmetric Matrices

- (계속) 대칭 행렬의 경우 Eigenvalue와 pivot값의 관계
  - (양수인 pivot값들의 개수)=(양수인 eigenvalue들의 개수)
  - (증명) 대칭 행렬이 주어졌을 때, pivot값이 존재하려면  $A = L_1 U_2$ 의 형태로 분리가 가능해야 함. 소거법을 적용하기 위해 행교환이 필요한 경우에는 pivot값이 없는 것으로 고려대상에서 제외.
  - Upper triangle인  $U$ 는 대각선에 pivot값들이 존재하므로 다음과 같은 분해가 가능함.

$$U_2 = D U_3 = \begin{bmatrix} d_1 & 0 & \cdots & 0 \\ 0 & d_2 & & 0 \\ \vdots & & \ddots & \vdots \\ 0 & 0 & & d_n \end{bmatrix} \begin{bmatrix} 1 & \square & \cdots & \square \\ 0 & 1 & & \square \\ \vdots & & \ddots & \vdots \\ 0 & 0 & & 1 \end{bmatrix}$$

- $A = L_1 D U_3 \rightarrow A^T = (U_3)^T D^T L_1^T = L_3 D U_1$ . 여기서  $L_3 \equiv U_3^T, U_1 \equiv L_1^T$ 의 대각선은 모두 1임.
- $A$ 는 대칭 행렬이므로  $A^T = (U_3)^T D L_1^T = A = L_1 D U_3$
- 이 경우  $L_1$ 과  $U_3$ 사이에는 transpose 관계가 성립해야 함. 따라서  $A = L D L^T$  형태의 분해가 가능함

## 6.4 Symmetric Matrices

- (계속) 대칭 행렬의 경우 Eigenvalue와 pivot값의 관계
  - (증명 계속) 앞에서  $A = LDL^T$  형태로 분해가 됨을 보였음.
  - $\begin{bmatrix} 1 & 3 \\ 3 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 3 & 1 \end{bmatrix} \begin{bmatrix} 1 & \\ & -8 \end{bmatrix} \begin{bmatrix} 1 & 3 \\ 0 & 1 \end{bmatrix}$
  - 만약  $L$  행렬과  $L^T$  행렬을 천천히 단위 행렬로 변형시킬 때 ( $A \rightarrow D$ ), eigenvalue의 변화를 고려.
  - $L$  행렬과  $L^T$  행렬이 0으로 변화하려면 대각이 아닌 성분(위의 경우 "3")이 점차 0으로 변해야 함.
  - 대각이 아닌 성분이 모두 0으로 변하면  $A = LDL^T = IDI^T$ 의 eigenvalue는 처음  $\lambda_1 = 4, \lambda_2 = -2$ 에서 행렬의 pivot값인  $d_1 = 1, d_2 = -8$ 로 변하게 됨.
  - 이 과정에서 만약 서로 대응되는 eigenvalue  $\lambda_j$ 와 pivot  $d_j$ 의 부호가 달랐다면  $\lambda_j$ 가 변하면서 0으로 거쳐야 하므로, 중간에 eigenvalue가 0이 되는 시점이 발생하고, 이 순간에는 행렬이 singular가 되어야 함.
  - 하지만, 위의 과정에서  $A = LDL^T$  형태는 계속 유지되고, 따라서  $L$ 의 값이 바뀌어도  $D$ 는 일정하여 pivot값은 바뀌지 않고 계속 유지되므로  $A$ 는 계속 가역행렬이라 singular가 될 수 없음.
  - 따라서, Eigenvalue와 pivot값의 부호는 일치해야 함.

## 6.5 Positive Definite Matrices

- Positive definite 행렬 (정부호 행렬)
  - ▣ **대칭** 행렬 중 모든 eigenvalue 값들이 0보다 큰 행렬
  - ▣ 그러면 positive semidefinite 행렬이란?
  - ▣ 또 다른 형태의 정의: 임의의 모든 0이 아닌 벡터  $x$ 에 대해  $x^T A x > 0$ 이 항상 성립하면, 행렬  $A$ 는 positive definite 행렬이다.
  - ▣ 만약 행렬  $A$ 와  $B$ 가 positive definite 행렬이면,  $A+B$ 도 positive definite 행렬이다. Why?
  - ▣ 임의의 행렬  $R$ 이 주어졌을 때,  $A = R^T R$ 에 대해 다음 중 틀린 것은?
    - 1.  $A = R^T R$ 은 항상 정사각 행렬이다.
    - 2.  $A = R^T R$ 은 항상 대칭 행렬이 된다.
    - 3.  $A = R^T R$ 은 항상 positive definite 행렬이 된다.

## 6.5 Positive Definite Matrices

- 행렬  $R$ 의 열이 모두 독립이면,  $A = R^T R$ 은 항상 positive definite 행렬이 된다.
  - (증명)  $\mathbf{x}^T R^T R \mathbf{x} = (R\mathbf{x})^T (R\mathbf{x}) \geq 0$  이다.
  - 여기서 항상 positive definite 이 되려면, 0이 아닌 벡터  $\mathbf{x}$ 에 대해 항상  $R\mathbf{x}$ 는 0이 아니어야 한다.
  - 0이 아닌 벡터  $\mathbf{x}$ 에 대해  $R\mathbf{x} = 0$ 인 경우가 존재하면,  $R$ 의 모든 열은 독립일 수 없다. Why?
- 위의 증명으로부터 임의의 행렬  $R$ 이 주어지면, 열의 독립여부에 상관없이  $A = R^T R$ 은 항상 positive semidefinite 행렬이 된다.
- 행렬  $A$ 가 positive definite 행렬이면, 그 역행렬도 positive definite 행렬인가?
  - 행렬  $A$ 는 대칭 행렬이므로 대각 행렬로 변환 가능하고, 동시에 변환된 역행렬도 대각 행렬의 형태이어야 함.  $A$ 의 eigenvalue들이  $\lambda_1, \lambda_2, \dots, \lambda_d$ 이면, 역행렬의 eigenvalue는  $1/\lambda_1, 1/\lambda_2, \dots, 1/\lambda_d$ 이 됨 → positive definite

## 6.5 Positive Definite Matrices

### ■ Cholesky 분해

- 주어진 행렬  $A$ 가 positive definite이면,  $R^T R$ 의 형태로 분해 가능하다.
- (증명)  $A$ 가 positive definite이면 모든 pivot값들이 0보다 커서  $A = LU$  분해가 존재한다. 또한 대칭 행렬이므로  $A = LDL^T$ 로 표현이 가능하다.
- 예: 
$$\begin{bmatrix} 1 & 3 \\ 3 & 13 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 3 & 1 \end{bmatrix} \begin{bmatrix} 1 & \\ & 4 \end{bmatrix} \begin{bmatrix} 1 & 3 \\ 0 & 1 \end{bmatrix} =$$
$$\begin{bmatrix} 1 & 0 \\ 3 & 1 \end{bmatrix} \begin{bmatrix} 1 & \\ & \sqrt{4} \end{bmatrix} \begin{bmatrix} 1 & \\ & \sqrt{4} \end{bmatrix} \begin{bmatrix} 1 & 3 \\ 0 & 1 \end{bmatrix}$$
- 위와 같이  $A = LDL^T$ 는  $A = L\sqrt{D}\sqrt{D}L^T = (L\sqrt{D})(L\sqrt{D})^T = R^T R$ 의 형태로 분해 가능하고,  $R = \sqrt{D}L^T$ 의 형태이므로 열들이 독립이므로 positive definite임
- 위와 같이 positive definite 행렬을 분해하는 것을 Cholesky 분해라고 부름

## 6.5 Positive Definite Matrices

- 임의의 모든 0이 아닌 벡터  $\mathbf{x}$ 에 대해  $\mathbf{x}^T A \mathbf{x} > 0$ 이 항상 성립하면, 행렬  $A$ 는 positive definite 행렬이다.
  - ▣ 만약  $ax^2 + by^2$ 이 주어졌다면,  $x = y = 0$  이외의 값에서 이 식이 항상 0보다 크기 위한 조건은?
  - ▣ 행렬  $A = \begin{bmatrix} 3 & -1 \\ -1 & 3 \end{bmatrix}$ 가  $2 \times 2$ 인 경우,
    - ▣  $\mathbf{x} = \begin{bmatrix} x \\ y \end{bmatrix} \rightarrow \mathbf{x}^T A \mathbf{x} = \mathbf{x}^T \begin{bmatrix} 3 & -1 \\ -1 & 3 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} x & y \end{bmatrix} \begin{bmatrix} 3x - y \\ -x + 3y \end{bmatrix} = x(3x - y) + y(-x + 3y) = 3x^2 - 2xy + 3y^2$
    - ▣ 위의 식은 임의의  $x, y$ 에 대해 항상 0보다 큰가?
    - ▣  $\begin{bmatrix} 3 & -1 \\ -1 & 3 \end{bmatrix}$ 의 eigenvalue는 4와 2
    - ▣ 위의 식은  $(x + y)^2 + 2(x - y)^2$ 로 정리 가능. 이러한 형태는 우연일까?
    - ▣  $2\left(\frac{x+y}{\sqrt{2}}\right)^2 + 4\left(\frac{x-y}{\sqrt{2}}\right)^2$ 와 관련됨. 앞의 숫자들은?




## 6.5 Positive Definite Matrices

- (빠른 증명) 임의의 모든 0이 아닌 벡터  $\mathbf{x}$ 에 대해  $\mathbf{x}^T A \mathbf{x} > 0$ 이 항상 성립하면, 행렬  $A$ 는 positive definite 행렬이다.
  - 벡터  $\mathbf{x}$ 는 행렬  $A$ 의 eigenvector들의 1차 결합으로 표현 가능하므로,  $\mathbf{x} = q_1 \mathbf{q}_1 + q_2 \mathbf{q}_2 + \cdots + q_n \mathbf{q}_n$
  - $$\begin{aligned}\mathbf{x}^T A \mathbf{x} &= \mathbf{x}^T A (q_1 \mathbf{q}_1 + q_2 \mathbf{q}_2 + \cdots + q_n \mathbf{q}_n) \\ &= \mathbf{x}^T (q_1 \lambda_1 \mathbf{q}_1 + q_2 \lambda_2 \mathbf{q}_2 + \cdots + q_n \lambda_n \mathbf{q}_n) \\ &= (q_1 \mathbf{q}_1^T + q_2 \mathbf{q}_2^T + \cdots + q_n \mathbf{q}_n^T) (q_1 \lambda_1 \mathbf{q}_1 + q_2 \lambda_2 \mathbf{q}_2 + \cdots + q_n \lambda_n \mathbf{q}_n) \\ &= q_1^2 \lambda_1 \mathbf{q}_1^T \mathbf{q}_1 + q_2^2 \lambda_2 \mathbf{q}_2^T \mathbf{q}_2 + \cdots + q_n^2 \lambda_n \mathbf{q}_n^T \mathbf{q}_n \\ &= \lambda_1 q_1^2 + \lambda_2 q_2^2 + \cdots + \lambda_n q_n^2\end{aligned}$$
  - 기하학적 의미?

## 6.5 Positive Definite Matrices

### 좌표 변환

- 2차원 평면의 좌표가 주어졌을 때, 이를 새로운 좌표축에 대한 좌표를 구하는 방법은?




- $xy$ -좌표계 상에서 한 벡터  $\mathbf{v}$ 의 좌표가  $(x, y)$ 이면, 이 벡터는 좌표계의 단위 벡터들로 표현 가능함.

$$\mathbf{v} = x\hat{x} + y\hat{y}$$

- 새로운  $q_1q_2$ -좌표계가 주어졌을 때, 같은 벡터  $\mathbf{v}$ 를 서로 직교하는 단위 벡터  $\mathbf{q}_1, \mathbf{q}_2$ 의 좌표  $(q_x, q_y)$ 를 이용하여 아래와 같이 나타내려고 할 때,  $q_x, q_y$ 의 값을 결정하는 방법은?


$$\mathbf{v} = q_x\mathbf{q}_1 + q_y\mathbf{q}_2$$

## 6.5 Positive Definite Matrices



- $\mathbf{v} = x\hat{\mathbf{x}} + y\hat{\mathbf{y}} = q_x\mathbf{q}_1 + q_y\mathbf{q}_2$ 
  - ▣  $q_x$ 를 결정하기 위해서는  $\mathbf{q}_1, \mathbf{q}_2$ 가 서로 직교하는 성질을 이용.
  - ▣  $q_x = \mathbf{q}_1^T \mathbf{v} = \mathbf{q}_1^T (x\hat{\mathbf{x}} + y\hat{\mathbf{y}}) = (\mathbf{q}_1^T \hat{\mathbf{x}})x + (\mathbf{q}_1^T \hat{\mathbf{y}})y$
  - ▣  $\mathbf{q}_1^T \hat{\mathbf{x}}$ 를 결정하기 위해서는  $\mathbf{q}_1^T$  벡터를  $\hat{\mathbf{x}}$ 와  $\hat{\mathbf{y}}$ 의 벡터로 표현해야 함.
  - ▣  $\mathbf{q}_1, \mathbf{q}_2$ 가  $xy$ -좌표계 상에서 다음과 같은 좌표를 가진다고 가정
    - ▣  $\mathbf{q}_1 = \begin{bmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{bmatrix}, \mathbf{q}_2 = \begin{bmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{bmatrix}$
    - ▣  $\mathbf{q}_1, \mathbf{q}_2$  벡터는 다음과 같이  $\hat{\mathbf{x}}, \hat{\mathbf{y}}$ 의 1차결합으로 표현가능
      - ▣  $\begin{cases} \mathbf{q}_1 = \frac{1}{\sqrt{2}}\hat{\mathbf{x}} + \frac{1}{\sqrt{2}}\hat{\mathbf{y}} \\ \mathbf{q}_2 = \frac{1}{\sqrt{2}}\hat{\mathbf{x}} - \frac{1}{\sqrt{2}}\hat{\mathbf{y}} \end{cases}$  또는 일반적으로  $\begin{cases} \mathbf{q}_1 = q_{11}\hat{\mathbf{x}} + q_{12}\hat{\mathbf{y}} \\ \mathbf{q}_2 = q_{21}\hat{\mathbf{x}} + q_{22}\hat{\mathbf{y}} \end{cases}$
  - ▣  $\begin{cases} q_x = \mathbf{q}_1^T \mathbf{v} = (\mathbf{q}_1^T \hat{\mathbf{x}})x + (\mathbf{q}_1^T \hat{\mathbf{y}})y = q_{11}x + q_{12}y \\ q_y = \mathbf{q}_2^T \mathbf{v} = (\mathbf{q}_2^T \hat{\mathbf{x}})x + (\mathbf{q}_2^T \hat{\mathbf{y}})y = q_{21}x + q_{22}y \end{cases} \Rightarrow \begin{bmatrix} q_x \\ q_y \end{bmatrix} = \begin{bmatrix} q_{11} & q_{12} \\ q_{21} & q_{22} \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix}$

## 6.5 Positive Definite Matrices



- $\begin{bmatrix} q_x \\ q_y \end{bmatrix} = \begin{bmatrix} q_{11} & q_{12} \\ q_{21} & q_{22} \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix}$ 의 의미

- $\begin{cases} \mathbf{q}_1 = q_{11}\hat{x} + q_{12}\hat{y} \\ \mathbf{q}_2 = q_{21}\hat{x} + q_{22}\hat{y} \end{cases}$ 으로부터


$q_{ij}$ 는  $n$ 개의 직교하는 단위 벡터들  $(\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n)$  중  $i$ 번째 단위 행렬의  $j$ 번째 좌표 값을 나타냄을 알 수 있음

- 이들 단위 벡터들로 이루어진 orthogonal 행렬  $Q$ 를 고려하면  $Q = [\mathbf{q}_1 \ \mathbf{q}_2 \ \cdots \ \mathbf{q}_n]$ , 위의 식은 다음과 같다.

- $\begin{bmatrix} q_x \\ q_y \\ \vdots \end{bmatrix} = \begin{bmatrix} q_{11} & q_{12} & \cdots \\ q_{21} & q_{22} & \\ \vdots & & \ddots \end{bmatrix} \begin{bmatrix} x \\ y \\ \vdots \end{bmatrix} = Q^T \begin{bmatrix} x \\ y \\ \vdots \end{bmatrix} = Q^{-1} \begin{bmatrix} x \\ y \\ \vdots \end{bmatrix}$

- 단위 벡터들은 어디서 구할까? 행렬  $A$ 의 eigenvector
  - $\mathbf{x}^T A \mathbf{x} = \mathbf{x}^T (Q Q^{-1}) A (Q Q^{-1}) \mathbf{x} = (\mathbf{x}^T Q) (Q^{-1} A Q) (Q^{-1} \mathbf{x}) = (Q^{-1} \mathbf{x})^T (Q^{-1} A Q) (Q^{-1} \mathbf{x})$
  - $(Q^{-1} A Q)$ 은 어떤 형태의 행렬인가?

## 6.5 Positive Definite Matrices



- $\mathbf{x}^T \mathbf{A} \mathbf{x} = (\mathbf{Q}^{-1} \mathbf{x})^T (\mathbf{Q}^{-1} \mathbf{A} \mathbf{Q}) (\mathbf{Q}^{-1} \mathbf{x})$

- $$\begin{bmatrix} q_x \\ q_y \\ \vdots \end{bmatrix} = \mathbf{Q}^{-1} \begin{bmatrix} x \\ y \\ \vdots \end{bmatrix}$$


- $(\mathbf{Q}^{-1} \mathbf{A} \mathbf{Q}) = \Lambda$ 은 대각 행렬이므로

- $\mathbf{x}^T \mathbf{A} \mathbf{x} = (\mathbf{Q}^{-1} \mathbf{x})^T (\mathbf{Q}^{-1} \mathbf{A} \mathbf{Q}) (\mathbf{Q}^{-1} \mathbf{x}) =$

$$\begin{bmatrix} q_x & q_y & \cdots \end{bmatrix} \begin{bmatrix} \lambda_x & 0 & \cdots \\ 0 & \lambda_y & \\ \vdots & & \ddots \end{bmatrix} \begin{bmatrix} q_x \\ q_y \\ \vdots \end{bmatrix} = \lambda_x q_x^2 + \lambda_y q_y^2 + \cdots$$

- $q_x = q_y = \cdots = 0$  이외의 값에서 이 식이 항상 0보다 크기 위한 조건은?

## 6.5 Positive Definite Matrices



### Example

- ▣  $A = \begin{bmatrix} 3 & -1 \\ -1 & 3 \end{bmatrix}$ 가 주어졌을 때, 간략화 된  $\mathbf{x}^T A \mathbf{x}$ 의 식을 구하려면?
- ▣  $A$ 의 eigenvalue와 eigenvector는 다음과 같음.
- ▣  $\lambda_1 = 2, q_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \lambda_2 = 4, q_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$
- ▣  $Q = [q_1 \quad q_2] = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}, Q^{-1} = Q^T = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$
- ▣  $\Lambda = Q^{-1} A Q = Q^{-1} \begin{bmatrix} 3 & -1 \\ -1 & 3 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 2 & 4 \\ 2 & -4 \end{bmatrix} = \frac{1}{2} \begin{bmatrix} 4 & 0 \\ 0 & 8 \end{bmatrix} = \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix}$
- ▣  $\begin{bmatrix} q_x \\ q_y \end{bmatrix} = Q^{-1} \begin{bmatrix} x \\ y \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} x + y \\ x - y \end{bmatrix}$
- ▣  $\mathbf{x}^T A \mathbf{x} = (Q^{-1} \mathbf{x})^T (Q^{-1} A Q) (Q^{-1} \mathbf{x}) = (Q^{-1} \mathbf{x})^T \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} x + y \\ x - y \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} x + y & x - y \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 2(x + y) \\ 4(x - y) \end{bmatrix} = 2 \left( \frac{x+y}{\sqrt{2}} \right)^2 + 4 \left( \frac{x-y}{\sqrt{2}} \right)^2$

## 6.5 Positive Definite Matrices

### ■ 요약

- 언제  $\mathbf{x}^T \mathbf{A} \mathbf{x}$ 를  $[q_x \ q_y \ \cdots] \begin{bmatrix} \lambda_x & 0 & \cdots \\ 0 & \lambda_x & \\ \vdots & & \ddots \end{bmatrix} \begin{bmatrix} q_x \\ q_y \\ \vdots \end{bmatrix}$ 와 같은 형태로 변형이 가능?
  - $Q$ 가 대칭행렬이면 항상 직교하는 eigenvector를 구할 수 있음
- 만약 eigenvalue중 음수가 발생하면?
  - 대칭행렬이면 여전히 직교하는 좌표계에 대해  $ax^2 + by^2 + \cdots$ 의 형태를 얻음
  - 하지만, 전체적인 함수는 말안장 형태(saddle point)를 띄게 되어 최소값이 존재하지 않음
- 만약 특정 eigenvalue가 0이면?
  - 대칭행렬이면 여전히 직교하는 좌표계에 대해  $ax^2 + by^2 + \cdots$ 의 형태를 얻음
  - 하지만, 이중 eigenvalue가 0에 해당하는 축으로는 값이 계속 0이 됨 → positive semidefinite

## 6.6 Similar Matrices

### ■ 닮은 행렬

- 행렬  $A$ 와  $B$  사이에  $B = M^{-1}AM$  형태의 변환을 해줄 수 있는  $M$ 을 찾을 수 있는 경우 두 행렬은 닮았다고 정의한다.
- 닮은 행렬들을 모은 집합을 family라고 부른다.
- 같은 family에 있는 행렬들은 대각 행렬 (또는 거의 대각 행렬에 가까운 행렬)에 의해 대표될 수 있다.
- 행렬이 가진 eigenvector들만으로 전체 공간을 생성할 수 있는 경우,  $S^{-1}AS = \Lambda$ 의 관계를 가지므로  $A$ 와  $\Lambda$ 은 닮은 행렬이다.
- Example)  $A = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}$ ,  $\Lambda = \begin{bmatrix} 3 & 0 \\ 0 & 1 \end{bmatrix}$ 은?
- $M = \begin{bmatrix} 1 & 4 \\ 0 & 1 \end{bmatrix}$ ,  $M^{-1} = \begin{bmatrix} & \\ & \end{bmatrix}$
- $B = M^{-1}AM$



## 6.6 Similar Matrices

- 닮은 행렬은 같은 eigenvalue를 가진다.
  - ▣  $B = M^{-1}AM$ 가 주어진 경우,  $A$ 의 eigenvector  $x$ 가 주어지면  $M^{-1}x$ 는  $B$ 의 eigenvector이고, 같은 eigenvalue를 가진다.
  - ▣ 거꾸로 2개의 행렬이 가진  $n$ 개의 서로 다른 eigenvalue가 모두 같다면, 두 행렬은 같은 대각 행렬과 닮은 관계이다.
  - ▣ 만약 행렬이 중복된 eigenvalue를 가진다면 대각화가 불가능한 경우도 존재한다.
  - ▣  $A = \begin{bmatrix} 4 & 1 \\ 0 & 4 \end{bmatrix}, B = \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix}$  두 행렬 모두 4,4의 eigenvalue를 가진다.
  - ▣ 행렬  $A$ 는 1개의 eigenvector를 가지기 때문에 대각화가 불가능
  - ▣ 행렬  $B$ 는 2개의 eigenvector를 가지므로 대각화가 가능 → 행렬  $B$ 는 닮은 행렬은 자기 자신밖에 없다.

## 6.7 Singular Value Decomposition

- 특이값 분해 (Singular Value Decomposition, SVD)
  - $A = U\Sigma V^T$ , 여기서  $U, V$ 는 직교행렬,  $\Sigma$ 는 대각 행렬임
  - $A$ 는 정사각 행렬일 필요가 없음
  - $A$ 가 대칭, positive definite 행렬의 경우  $A = Q\Lambda Q^T$ 는 SVD의 특수한 경우임
  - $A$ 가 대칭이 아닐 경우 좀 더 일반적인 경우는  $A$ 가  $n$ 개의 다른 eigenvector를 가지는 경우  $A = S\Lambda S^{-1}$ 가 가능함을 배움
  - 행렬  $A$ 를 행벡터 공간내 임의의 벡터  $v_1$ 를 열벡터 공간내 다른 벡터  $u_1 = Av_1$ 에 mapping하는 함수로 생각할 수 있음.
  - SVD는 열벡터 공간의 직교하는 기저에 mapping될 수 있는 행벡터 공간의 직교하는 기저에 찾는 문제임:  $Av_i = \sigma_i u_i$
  - 다음을 만족하는 행벡터 공간의 직교하는 기저  $v_1, v_2, \dots, v_r$ 를 찾아야 함
  - $A[v_1 \ v_2 \ \cdots \ v_r] = [\sigma_1 u_1 \ \sigma_2 u_2 \ \cdots \ \sigma_r u_r] =$   
 $[u_1 \ u_2 \ \cdots \ u_r] \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix}$
  - 여기서  $u_1, u_2, \dots, u_r$ 는 열벡터 공간의 직교하는 기저임

## 6.7 Singular Value Decomposition

- 다음을 만족하는 행벡터 공간의 직교하는 기저  $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 를 찾아야 함
- $A[\mathbf{v}_1 \ \mathbf{v}_2 \ \cdots \ \mathbf{v}_r] = [\sigma_1 \mathbf{u}_1 \ \sigma_2 \mathbf{u}_2 \ \cdots \ \sigma_r \mathbf{u}_r] =$   
$$[\mathbf{u}_1 \ \mathbf{u}_2 \ \cdots \ \mathbf{u}_r] \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix}$$
- 여기서  $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_r$ 는 열벡터 공간의 직교하는 기저임
- 행벡터 공간의  $\mathbf{R}^n$ 공간의 부분 공간이지만, nullspace의 기저  $\mathbf{v}_{r+1}, \dots, \mathbf{u}_n$ 까지 합친 경우에는 전체  $\mathbf{R}^n$ 공간을 span할 수 있고, 이때 해당하는  $\sigma_{r+1}, \dots, \sigma_n$ 은 모두 0임
- $AV = U\Sigma \rightarrow A = U\Sigma V^T$
- $\rightarrow A^T A = V\Sigma U^{-1} U\Sigma V^T = V\Sigma^2 V^T = V \begin{bmatrix} \sigma_1^2 & & \\ & \ddots & \\ & & \sigma_r^2 \end{bmatrix} V^T$