

6.7 Singular Value Decomposition

- 특이값 분해 (Singular Value Decomposition, SVD)
 - 임의의 선형변환에 해당하는 행렬 A 가 주어졌을 때, SVD는 열벡터 공간의 직교하는 기저에 mapping될 수 있는 행벡터 공간의 직교하는 기저를 찾는 문제임
- Example
 - 입력 공간이 \mathbf{R}^3 , 출력 공간은 \mathbf{R}^2 , 기존 좌표축을 기저로 사용하는 선형변환이 행렬 $A = \begin{bmatrix} 1 & 1 & 1 \\ 1 & -1 & 0 \end{bmatrix}$ 의 형태로 주어졌다고 가정.
 - 입력 공간의 직교하는 두 벡터 $(1,0,0)$, $(0,0,1)$ 에 해당하는 출력 공간의 벡터는 직교하는가?
 - $\begin{bmatrix} 1 & 1 & 1 \\ 1 & -1 & 0 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 & 1 & 1 \\ 1 & -1 & 0 \end{bmatrix} \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$
 - “직교하는 기저” → “직교하는 기저”의 장점
 - 좌표값에 일종의 eigenvalue만 곱하면 됨 → 직교하지 않으니 포기?

6.7 Singular Value Decomposition

- 특이값 분해 (Singular Value Decomposition, SVD)
 - $A = U\Sigma V^T$ (여기서 U, V 는 직교행렬, Σ 는 대각 행렬임)
 - 위와 같은 형태를 목표로 다시 도전

- $A^T A = V\Sigma^T U^{-1} U\Sigma V^T = V\Sigma^T \Sigma V^T = V \begin{bmatrix} \sigma_1^2 & & \\ & \ddots & \\ & & \sigma_r^2 \end{bmatrix} V^T$

- Example

- 입력 공간이 \mathbf{R}^3 , 출력 공간은 \mathbf{R}^2 ,
 - $A^T A = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 \\ 1 & -1 & 0 \end{bmatrix} = \begin{bmatrix} 3 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 0 \end{bmatrix} \rightarrow$ 대칭행렬 우연?
 - Eigenvalue & eigenvector: $\lambda = 3, 2, 0, \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ -2 \end{bmatrix}$

6.7 Singular Value Decomposition

- (계속) Example $A = U\Sigma V^T$

- $A^T A = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 \\ 1 & -1 & 0 \end{bmatrix} = \begin{bmatrix} 2 & 0 & 1 \\ 0 & 2 & 1 \\ 1 & 1 & 1 \end{bmatrix}$

- Eigenvalue & eigenvector: $\lambda = 3, 2, 0, \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} -1 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \\ -2 \end{bmatrix}$

- $V = \begin{bmatrix} \\ \\ \end{bmatrix}, \Sigma^T \Sigma = \begin{bmatrix} \sigma_1^2 & & \\ & \sigma_2^2 & \\ & & \sigma_3^2 \end{bmatrix} = \begin{bmatrix} \\ \\ \end{bmatrix}$

- 만약 eigenvalue가 음수이면?

- $AV = \begin{bmatrix} 1 & 1 & 1 \\ 1 & -1 & 0 \end{bmatrix} \begin{bmatrix} 1/\sqrt{3} & -1/\sqrt{2} & 1/\sqrt{6} \\ 1/\sqrt{3} & 1/\sqrt{2} & 1/\sqrt{6} \\ 1/\sqrt{3} & 0 & -2/\sqrt{6} \end{bmatrix} = \begin{bmatrix} \\ \\ \end{bmatrix}$

6.7 Singular Value Decomposition

- (계속) Example $A = U\Sigma V^T$
 - 일반적으로 U 를 모르므로 $AA^T = U\Sigma V^T V\Sigma^T U^T = U\Sigma\Sigma^T U^T$
 - $AA^T = \begin{bmatrix} 1 & 1 & 1 \\ 1 & -1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} 3 & 0 \\ 0 & 2 \end{bmatrix}$
 - Eigenvalue & eigenvector: $\lambda = 3, 2, \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix}$
 - $U = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}, \Sigma\Sigma^T = \begin{bmatrix} \sigma_1^2 & & \\ & \sigma_2^2 & \\ & & 0 \end{bmatrix} = \begin{bmatrix} 3 & 0 & 0 \\ 0 & 2 & 0 \end{bmatrix}$
 - Using $AV = \begin{bmatrix} 1 & 1 & 1 \\ 1 & -1 & 0 \end{bmatrix} \begin{bmatrix} 1/\sqrt{3} & -1/\sqrt{2} & 1/\sqrt{6} \\ 1/\sqrt{3} & 1/\sqrt{2} & 1/\sqrt{6} \\ 1/\sqrt{3} & 0 & -2/\sqrt{6} \end{bmatrix} = \begin{bmatrix} \sqrt{3} & 0 & 0 \\ 0 & -\sqrt{2} & 0 \end{bmatrix}$

$$= [\sigma_1 \mathbf{u}_1 \quad \sigma_2 \mathbf{u}_2 \quad \cdots \quad \sigma_r \mathbf{u}_r] = [\mathbf{u}_1 \quad \mathbf{u}_2 \quad \cdots \quad \mathbf{u}_r] \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix}$$
 - $A = U\Sigma V^T = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} \sqrt{3} & 0 & 0 \\ 0 & \sqrt{2} & 0 \end{bmatrix} \begin{bmatrix} 1/\sqrt{3} & -1/\sqrt{2} & 1/\sqrt{6} \\ 1/\sqrt{3} & 1/\sqrt{2} & 1/\sqrt{6} \\ 1/\sqrt{3} & 0 & -2/\sqrt{6} \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}$
 - 부호가 왜 틀린 것일까?
 - 행렬의 크기?

6.7 Singular Value Decomposition

- 특이값 분해 (Singular Value Decomposition, SVD)
 - $A = U\Sigma V^T$, 여기서 U, V 는 직교행렬, Σ 는 대각 행렬임
 - A 는 정사각 행렬일 필요가 없음
 - A 가 대칭, positive definite 행렬의 경우 $A = Q\Lambda Q^T$ 는 SVD의 특수한 경우임
 - A 가 대칭이 아닐 경우 좀 더 일반적인 경우는 A 가 n 개의 다른 eigenvector를 가지는 경우 $A = S\Lambda S^{-1}$ 가 가능함을 배움
 - 행렬 A 를 행벡터 공간내 임의의 벡터 v_1 를 열벡터 공간내 다른 벡터 $u_1 = Av_1$ 에 mapping하는 함수로 생각할 수 있음.
 - SVD는 열벡터 공간의 직교하는 기저에 mapping될 수 있는 행벡터 공간의 직교하는 기저를 찾는 문제임: $Av_i = \sigma_i u_i$
 - 다음을 만족하는 행벡터 공간의 직교하는 기저 v_1, v_2, \dots, v_r 를 찾아야 함
 - $A[v_1 \ v_2 \ \cdots \ v_r] = [\sigma_1 u_1 \ \sigma_2 u_2 \ \cdots \ \sigma_r u_r] =$
 $[u_1 \ u_2 \ \cdots \ u_r] \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix}$
 - 여기서 u_1, u_2, \dots, u_r 는 열벡터 공간의 직교하는 기저임

6.7 Singular Value Decomposition

- 다음을 만족하는 행벡터 공간의 직교하는 기저 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_r$ 를 찾아야 함
- $A[\mathbf{v}_1 \ \mathbf{v}_2 \ \cdots \ \mathbf{v}_r] = [\sigma_1 \mathbf{u}_1 \ \sigma_2 \mathbf{u}_2 \ \cdots \ \sigma_r \mathbf{u}_r] =$
$$[\mathbf{u}_1 \ \mathbf{u}_2 \ \cdots \ \mathbf{u}_r] \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix}$$
- 여기서 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_r$ 는 열벡터 공간의 직교하는 기저임
- 행벡터 공간의 \mathbf{R}^n 공간의 부분 공간이지만, nullspace의 기저 $\mathbf{v}_{r+1}, \dots, \mathbf{v}_n$ 까지 합친 경우에는 전체 \mathbf{R}^n 공간을 span할 수 있고, 이때 해당하는 $\sigma_{r+1}, \dots, \sigma_n$ 은 모두 0임
- $AV = U\Sigma \rightarrow A = U\Sigma V^T$
- $\rightarrow A^T A = V\Sigma U^{-1} U\Sigma V^T = V\Sigma^2 V^T = V \begin{bmatrix} \sigma_1^2 & & \\ & \ddots & \\ & & \sigma_r^2 \end{bmatrix} V^T$

6.7 Singular Value Decomposition

- $AV = U\Sigma \rightarrow A = U\Sigma V^T$
- $\rightarrow A^T A = V\Sigma U^{-1}U\Sigma V^T = V\Sigma^2 V^T = V \begin{bmatrix} \sigma_1^2 & & \\ & \ddots & \\ & & \sigma_r^2 \end{bmatrix} V^T$
- 위의 행렬은 $Q\Lambda Q^T$ 의 형태이고, $A^T A$ 는 positive semidefinite 행렬이므로 대각화가 가능함. V 는 $A^T A$ 행렬의 eigenvector이고 σ_i^2 는 $A^T A$ 행렬의 eigenvalue임.
- U 행렬 역시 유사한 방식으로 구할 수 있음.

6.7 Singular Value Decomposition

- 계산 과정에서 문제가 없기 위해서는 $A^T A$ 와 AA^T 가 같은 eigenvalue를 가져야 한다. 이것은 항상 보장되는가?
- 이보다 좀 더 근본적으로 AB 와 BA 가 항상 같은 eigenvalue를 가짐
 - (증명) 행렬 AB 가 $AB\mathbf{x} = \lambda\mathbf{x}$ 를 만족하는 eigenvector \mathbf{x} 와 eigenvalue λ 를 가진다고 가정. 이 경우 $B\mathbf{x}$ 는 BA 의 eigenvector이고 λ 를 eigenvalue 가진다. Why?
 - $BA(B\mathbf{x}) = B(AB)\mathbf{x} = B(\lambda\mathbf{x}) = \lambda(B\mathbf{x})$
- 따라서 $A^T A$ 와 AA^T 는 항상 같은 eigenvalue를 가져야한다.

6.7 Singular Value Decomposition

- Example

- ▣ $A = \begin{bmatrix} 4 & 4 \\ -3 & 3 \end{bmatrix}$

6.7 Singular Value Decomposition

- SVD의 완전히 다른 관점

- ▣ 여러 개의 rank 1인 행렬들의 합으로 분해하는 과정

- ▣
$$A[\mathbf{v}_1 \quad \mathbf{v}_2 \quad \cdots \quad \mathbf{v}_r] = [\mathbf{u}_1 \quad \mathbf{u}_2 \quad \cdots \quad \mathbf{u}_r] \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix}$$

- ▣
$$A = [\mathbf{u}_1 \quad \mathbf{u}_2 \quad \cdots \quad \mathbf{u}_r] \begin{bmatrix} \sigma_1 & & \\ & \ddots & \\ & & \sigma_r \end{bmatrix} \begin{bmatrix} \mathbf{v}_1^T \\ \mathbf{v}_2^T \\ \vdots \\ \mathbf{v}_r^T \end{bmatrix}$$

- ▣
$$= \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^T + \cdots + \sigma_r \mathbf{u}_r \mathbf{v}_r^T$$

- ▣ 행렬 $\sigma_1 \mathbf{u}_1 \mathbf{v}_1^T$ 의 rank는?